

고객 이탈 예측 및 LTV 분석

제 2회 데이터 분석 경진대회

팀 제타바이트

한국데이터정보과학회 × SAS KOREA

CONTENTS

01 문제 배경 및 중요성

02 데이터

03 피쳐 엔지니어링

04 모델 선택

05 모델링 최종 전략

06 최종 결과 및 비즈니스 시사점

문제 정의

Task 1: 고객 이탈 예측 (Churn)

- 신규 고객 유치 비용 > 기존 고객 유지 비용 (약 5배)
- 수익성 방어
- 마케팅 비용 최적화
- 평가: ROC-AUC

Task 2: 고객 생애 가치 예측 (LTV)

- 고객별 맞춤형 전략 수립
- 한정된 자원의 효율적 배분
- 이탈 예측과의 시너지 효과 발생
- 평가: RMSE

데이터 구조

customer_info

8개 컬럼

- 성별
- 연령
- 지역
- 고객 ID
- 소득 구간
- 가입일
- 결혼 여부
- 선호 카테고리

transaction_history

7개 컬럼

- 고객 ID
- 구매 일자
- 구매 금액
- 거래 고유 ID
- 구매 채널
- 구매 카테고리
- 할부 여부

finance_profile

9개 컬럼

- 고객 ID
- 신용 점수
- 신용카드 수
- 예적금 금액
- 대출 잔액
- 6개월 현금 사용액
- 6개월 카드 사용액
- 금융 연체 일수
- 자산 변동 추세

Train

60,000명

Test

40,000명

이탈률

9.88%

관측 기간




6개월

데이터 정제/전처리

Isolation Forest 알고리즘을 이용한 이상치 처리

산출된 이상치 점수를 기준으로 상위 3%에 해당하는 이상치 처리

IsolationForest 이상치 탐지 결과




데이터 정제/전처리

범주형 변수 전부 무관

성별, 지역, 결혼 여부, 선호 카테고리, 소득 구간 모두 이탈률 차이 0.6%p 이하 → 과감히 제거 / 순서형 변환 / 범주형 인코딩

범주형 변수별 이탈률 — 모두 0.6%p 이내 (무관)



주요 피처 엔지니어링

거래 집계

22개

금액 통계, 건수, 할부, decay 가중, 윈도우(14/90일), 모멘텀

SVD 임베딩

10개

구매 카테고리 시퀀스 → TF-IDF + bigram → SVD 10차원 압축

금융 파생

8+3개

원본 8개 + debt_to_asset, short_term_debt_ratio, anomaly_score

고객 정보

4개

연령, 가입기간, 소득구간, 선호카테고리

RFM Rank

1개

churn_resistance_score: R/F/M의 rank 기반 이탈 저항력 (0~1)

핵심 파생변수 상세

short_term_debt_ratio

파생변수 생성식

$(\text{현금서비스} + \text{카드론}) / \text{예적금 잔액}$

- 기존 debt_to_asset_ratio는 전체 부채를 사용
- 단기 고위험 부채(현금서비스+카드론)만 분리
- 지금 당장 급전이 필요한 정도를 직접 측정
- AUC 개선 효과: +0.0013


churn_resistance_score

파생변수 생성식


$(F_rank + M_rank + (1-R_rank)) / 3$

- R(최근성), F(빈도), M(금액) 절대값 백분위(rank)로 변환
- 극단값의 영향 제거하여 트리의 분기점을 안정화
- std 개선: 0.00090 → 0.00072

파생변수 중요도



모델 선택 근거



단일 모델(LightGBM) 선택의 당위성
: 성능 vs 연산 비율의 트레이드 오프

> LightGBM 단독 선택 근거

모델	LightGBM	XGBoost	CatBoost	LGBM+XGB	LGBM+CAT	ALL
AUC	0.8004	0.7960	0.7975	0.7988	0.7995	0.7992
비용(학습 시간)	15분	40분	20분	65분	55분	80분

실험 여정 — 시도와 검증


효과 있었던 시도

✓ short_term_debt_ratio 파생	+0.0013
✓ Optuna 하이퍼파라미터 튜닝	+0.0008
✓ CatBoost/XGBoost 제외 (LGBM 단독)	+0.0009
✓ 전처리 파라미터 동시 튜닝	+0.0025
✓ churn_resistance_score (RFM Rank)	std↓20%

효과 없었던 시도

- ✗ Finance 교차 피처 17개
- ✗ 시계열 SVD, Gap 프로파일
- ✗ Finance 클러스터링 (K-means)
- ✗ 인구통계 프로파일 (PCA)
- ✗ 연속형→범주형 변환 (binning)
- ✗ LGBM 변형 앙상블
- ✗ GA 피처 선택 (43→29개)
- ✗ 유전 프로그래밍 수식 탐색 (907개)

실험 여정 — 시도와 검증



모델링 최종 전략

2-Stage Cascading 구조

Stage 1: Churn (LightGBM Binary)

Stage 2: LTV (LightGBM Tweedie)

연결: Churn 예측값 → LTV 피처로 활용

검증 전략


5-Fold Stratified CV

× Multi-seed 평균 (5~10개)

→ 단일 seed 과적합 방지

→ LB 안정성 확보

2-Stage Cascading 파이프라인



최종 결과

Churn AUC

0.7993

Total Score

0.46978

LTV RMSE

1,347,538

핵심 성과

- ✓ 도메인 기반 파생변수(STR)가 모든 자동화 기법보다 효과적
- ✓ Multi-seed 검증으로 과적합을 사전 차단
- ✓ Churn/LTV 분리 파이프라인으로 Task별 최적화
- ✓ 30회 이상의 체계적 실험 기반 의사결정

비즈니스 시사점

이탈 핵심 동인: 단기 부채


- 현금서비스와 카드론 의존도가 높은 고객
- 해당 고객 대상 금리 우대나 상환 컨설팅으로 선제 대응 가능

행동 패턴 > 인구통계

- 성별, 지역 등 인구통계의 관련성 적음
- 행동 패턴(구매 빈도 변화, 최근 소비 감소 등)이 핵심 변수

고객 가치 차별화 전략

- 유지 고객의 LTV가 이탈 고객의 19.6배.
- 이탈 방지에 투입하는 마케팅 비용 대비 ROI가 극히 높음.



- 신규 고객 유치 비용 > 기존 고객 유지 비용 (약 5배)
- 한정된 자원의 효율적 배분
- 고객별 맞춤형 전략 수립
- 마케팅 비용 최적화
- 수익성 방어

감사합니다

팀 제타바이트

Q & A